

PROPOSAL

KLASIFIKASI GOLONGAN KENDARAAN PADA JALAN TOL DI INDONESIA BERBASIS CITRA CCTV



Disusun oleh:

Nama	NIM
1. Gradien Ridholumintu	25/555306/PA/23271
2. Eugenia Elvira Inamorata	25/557119/PA/23404
3. Muhammad Fathan Romiza	25/560518/PA/23623
4. Radistha Kriska Dahana Purusa	25/561345/PA/23665
5. Naryama Affan Kuntadi	25/564501/PA/23776

**PROGRAM STUDI S-1 ILMU KOMPUTER
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

Tahun 2026

I. Latar Belakang

Jalan tol merupakan salah satu infrastruktur transportasi yang berperan penting dalam mendukung mobilitas masyarakat dan distribusi barang di Indonesia. Dalam pengoperasiannya, kendaraan dikelompokkan berdasarkan jenis dan karakteristik tertentu karena setiap golongan dapat dikenakan tarif yang berbeda. Penggolongan kendaraan yang digunakan pada jalan tol terdiri atas lima golongan. Golongan I mencakup sedan, jip, *pick-up*/truk kecil, dan bus, sedangkan Golongan II sampai Golongan V merupakan truk yang dibedakan berdasarkan jumlah gandar [1]. Oleh karena itu, identifikasi golongan kendaraan menjadi salah satu bagian penting dalam pengelolaan dan transaksi jalan tol.

Seiring dengan meningkatnya mobilitas kendaraan di jalan tol, kebutuhan akan identifikasi golongan kendaraan yang efektif juga semakin penting. Proses identifikasi secara manual membutuhkan pengamatan terhadap karakteristik setiap kendaraan dan menjadi kurang efisien apabila dilakukan secara terus-menerus terhadap jumlah kendaraan yang besar. Di sisi lain, kamera pengawas atau CCTV yang telah tersedia di lingkungan jalan tol menghasilkan citra kendaraan yang dapat dimanfaatkan untuk mengenali karakteristik fisiknya. Informasi visual seperti bentuk kendaraan, susunan roda, dan jumlah gandar dapat menjadi dasar untuk membedakan golongan kendaraan yang melintas.

Penelitian klasifikasi kendaraan pada konteks jalan tol Indonesia telah dilakukan sebelumnya. Sasongko dkk. menyusun dataset lima golongan kendaraan sesuai klasifikasi tarif Indonesia dan menguji pendekatan berbasis *transfer learning* [2], [3]. Citra pada dataset tersebut diperoleh menggunakan kamera telepon pintar. Kondisi ini berbeda dengan citra CCTV jalan tol, yang umumnya memiliki posisi kamera tetap tetapi menghasilkan objek dengan ukuran, jarak, pencahayaan, dan tingkat keterlihatan yang bervariasi.

Ketersediaan *InaTRC (Indonesia Toll Road Vehicle Classification Dataset)* memungkinkan kondisi tersebut dikaji menggunakan data CCTV jalan tol Indonesia. *InaTRC* dipublikasikan pada 2025 dan memuat 3.250 citra CCTV yang dikumpulkan pada Maret–Oktober 2022. Dataset ini menyediakan anotasi *bounding box* dalam format YOLO untuk lima golongan kendaraan, beserta pembagian awal data latih, validasi, dan uji [4]. Proses pengumpulan dan anotasi citra dari *live feed* CCTV juga dijelaskan melalui pengembangan saLFIA [5].

Penggunaan citra CCTV tetap menghadirkan beberapa tantangan. Kendaraan yang berada jauh dari kamera mempunyai *Region of Interest (ROI)* yang kecil sehingga detail roda dan gandar dapat berkurang setelah citra dinormalisasi. Sudut pandang tertentu juga dapat menyebabkan sebagian roda tertutup oleh badan kendaraan atau kendaraan lain. Selain itu, jumlah sampel antargolongan tidak selalu seimbang. Data CCTV juga bersifat sekuensial; frame yang berdekatan dapat memiliki isi visual yang sangat mirip. Jika frame yang berkaitan tersebar pada data latih dan data uji, hasil evaluasi dapat menjadi terlalu optimistis karena sebagian informasi pada data uji telah muncul dalam bentuk yang hampir sama pada saat pelatihan [6], [7].

Berdasarkan hal tersebut, penelitian ini berfokus pada klasifikasi lima golongan kendaraan jalan tol menggunakan pengolahan citra digital dan *machine learning* klasik.

Beberapa aspek yang dikaji meliputi pembentukan dan normalisasi *Region of Interest* (ROI), representasi ciri visual kendaraan, penanganan ketidakseimbangan kelas, dan pembagian data yang mempertimbangkan kemiripan antarframe. Histogram of Oriented Gradients (HOG) digunakan sebagai representasi fitur awal, sedangkan LightGBM digunakan sebagai salah satu pengklasifikasi yang diuji. Hasil eksperimen kemudian digunakan untuk menilai pengaruh masing-masing aspek terhadap kinerja klasifikasi.

II. Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah penelitian ini adalah:

1. Bagaimana merancang dan mengevaluasi pipeline pengolahan citra digital dan *machine learning* klasik untuk mengklasifikasikan lima golongan kendaraan jalan tol berdasarkan ROI kendaraan pada citra CCTV?
2. Sejauh mana representasi fitur, pembentukan ROI, dan resolusi citra memengaruhi kemampuan model dalam membedakan karakteristik antargolongan kendaraan, terutama Golongan II–V yang dibedakan berdasarkan jumlah gandar?
3. Bagaimana penanganan ketidakseimbangan kelas dan pembagian data yang mempertimbangkan kemiripan antarframe memengaruhi kinerja serta keandalan hasil evaluasi model?

III. Tujuan Penelitian

Penelitian ini bertujuan untuk:

1. Merancang dan mengimplementasikan pipeline klasifikasi lima golongan kendaraan jalan tol berbasis citra CCTV menggunakan tahapan pengolahan citra digital dan *machine learning* klasik.
2. Menganalisis pengaruh representasi fitur, pembentukan ROI, dan resolusi citra terhadap kemampuan model dalam membedakan karakteristik visual antargolongan kendaraan.
3. Mengevaluasi kinerja model dengan memperhatikan ketidakseimbangan kelas dan kemiripan antarframe serta menggunakan metrik yang tidak didominasi oleh kelas mayoritas.

IV. Manfaat Penelitian

a. Manfaat Teoritis

Penelitian ini diharapkan dapat memperkaya kajian di bidang pengolahan citra digital dan *machine learning* klasik, khususnya untuk klasifikasi kendaraan dari citra CCTV dengan distribusi kelas yang tidak seimbang. Hasil penelitian juga dapat memberikan gambaran mengenai pengaruh representasi fitur, ukuran dan konteks ROI, resolusi citra, serta pembagian data terhadap kemampuan klasifikasi lima golongan kendaraan.

b. Manfaat Praktis


1. Hasil penelitian dapat menjadi rujukan awal dalam pengembangan modul klasifikasi golongan kendaraan berbasis CCTV menggunakan fitur *handcrafted* dan pengklasifikasi klasik.
2. Analisis terhadap ukuran, resolusi, dan pembentukan ROI dapat memberikan gambaran mengenai kondisi citra yang masih memadai untuk membedakan karakteristik fisik kendaraan.
3. Pipeline dan hasil eksperimen dapat menjadi baseline atau pembanding bagi penelitian selanjutnya yang mengembangkan klasifikasi golongan kendaraan tol, baik menggunakan metode klasik maupun *deep learning*.

V. Solusi yang Diusulkan

Penelitian ini menggunakan anotasi *bounding box* pada InaTRC untuk mengambil *Region of Interest* (ROI) setiap kendaraan. Dengan demikian, eksperimen difokuskan pada pengenalan Golongan I–V berdasarkan informasi visual kendaraan tanpa terlebih dahulu membangun model deteksi objek. Bentuk badan kendaraan, struktur tepi, susunan roda, dan area di sekitar bagian bawah kendaraan menjadi informasi yang diperhatikan dalam proses klasifikasi.

Alur pengolahan disusun mengikuti kerangka AESFERM, yaitu *Acquisition, Enhancement, Segmentation, Feature Extraction, Encoding, Representation*, dan *Matching*. Citra dan anotasi terlebih dahulu dibaca dan diperiksa, kemudian ROI kendaraan diisolasi dan dinormalisasi. Ciri visual diekstraksi menggunakan fitur *handcrafted*; HOG digunakan sebagai representasi awal karena menggambarkan distribusi gradien dan struktur bentuk pada citra. Variasi resolusi, skala fitur, dan cakupan ROI selanjutnya dibandingkan untuk melihat pengaruhnya terhadap kemampuan klasifikasi.

Vektor fitur digunakan sebagai masukan bagi pengklasifikasi *machine learning* klasik. LightGBM digunakan sebagai salah satu model awal dan dapat dibandingkan dengan pengklasifikasi klasik lain pada representasi fitur yang sama. Ketidakseimbangan jumlah sampel antarkelas ditangani pada tahap pelatihan, misalnya melalui pembobotan kelas atau sampling. Pembagian awal data juga diaudit terhadap duplikasi dan kemiripan antarframe; apabila terdapat frame yang sangat berkaitan pada subset berbeda, pemisahan dilakukan pada tingkat kelompok agar data latih dan data uji tetap terpisah dengan baik.



Gambar 1: Gambaran umum pipeline klasifikasi yang diusulkan.

VI. Kajian Pustaka

6.1 Klasifikasi Kendaraan pada Jalan Tol Indonesia

Penggolongan kendaraan pada jalan tol di Indonesia berkaitan dengan jenis kendaraan dan jumlah gandar. Golongan I mencakup sedan, jip, *pick-up*/truk kecil, dan bus, sedangkan Golongan II–V dibedakan berdasarkan jumlah gandar pada kendaraan berat [1]. Perbedaan tersebut membuat bentuk kendaraan, susunan roda, dan proporsi badan kendaraan menjadi informasi visual yang relevan untuk proses klasifikasi.

Sasongko dkk. mengembangkan dataset lima kelas kendaraan untuk klasifikasi tarif jalan tol Indonesia. Citra pada dataset tersebut diperoleh menggunakan kamera telepon pintar dan kemudian digunakan dalam penelitian klasifikasi berbasis *transfer learning* dengan ResNet [2], [3]. Hasil penelitian tersebut menunjukkan bahwa penggolongan kendaraan dapat dipelajari dari karakteristik visual pada citra. Namun, kondisi pengambilan citranya berbeda dengan CCTV jalan tol yang memiliki posisi kamera tetap, jarak pandang yang bervariasi, dan latar belakang yang relatif konsisten pada setiap lokasi kamera.

InaTRC dikembangkan untuk kondisi yang lebih dekat dengan pemantauan menggunakan CCTV. Dataset ini memuat 3.250 citra CCTV jalan tol beserta anotasi kendaraan dalam format YOLO untuk lima golongan kendaraan [4]. Pengembangan saLFIA sebelumnya juga menunjukkan pemanfaatan *live feed* CCTV dalam proses pengumpulan dan anotasi citra kendaraan [5]. Pada data seperti ini, ukuran kendaraan pada frame, sudut pandang, pencahayaan, dan kemiripan antarframe perlu diperhatikan baik pada proses pengolahan citra maupun pada evaluasi model.

6.2 Representasi Bentuk dengan Histogram of Oriented Gradients

Histogram of Oriented Gradients (HOG) merupakan deskriptor citra yang merepresentasikan distribusi arah gradien lokal dan digunakan untuk menangkap informasi bentuk serta struktur tepi objek [8]. Untuk suatu citra intensitas I , komponen gradien horizontal dan vertikal dapat dinyatakan secara sederhana sebagai

$$g_x(x, y) = I(x + 1, y) - I(x - 1, y), \quad g_y(x, y) = I(x, y + 1) - I(x, y - 1). \quad (1)$$

Besarnya gradien dan arah lokal kemudian dihitung dengan

$$m(x, y) = \sqrt{g_x(x, y)^2 + g_y(x, y)^2}, \quad \theta(x, y) = \text{atan2}(g_y(x, y), g_x(x, y)). \quad (2)$$

Nilai gradien dirangkum ke dalam histogram orientasi pada sel-sel citra dan dinormalisasi pada blok yang berdekatan. Dengan cara ini, HOG lebih menekankan struktur tepi dan bentuk dibandingkan nilai intensitas piksel secara langsung.

Untuk klasifikasi kendaraan, representasi tersebut relevan karena perbedaan antar-kendaraan dapat terlihat pada bentuk kabin, badan kendaraan, bak, roda, dan bagian bawah kendaraan. HOG telah digunakan pada klasifikasi tipe kendaraan dan dapat dipasangkan dengan beberapa pengklasifikasi klasik [9]. Kualitas representasi HOG tetap dipengaruhi oleh resolusi citra, skala objek, dan bagian kendaraan yang tercakup di dalam ROI. Faktor-faktor tersebut menjadi bagian dari eksperimen pada penelitian ini.

6.3 Pengklasifikasi Klasik dan Ketidakseimbangan Kelas

Fitur *handcrafted* seperti HOG menghasilkan vektor fitur berdimensi tetap yang dapat digunakan oleh berbagai algoritma *machine learning* klasik. Metode yang umum digunakan untuk klasifikasi berbasis fitur antara lain Support Vector Machine, Random Forest, dan *gradient boosting*. LightGBM merupakan salah satu implementasi *gradient-boosted decision tree* yang dirancang untuk pelatihan yang efisien pada data berdimensi tinggi [10].

Distribusi kelas juga memengaruhi proses pelatihan. Pada data yang tidak seimbang, kesalahan pada kelas dengan jumlah sampel besar dapat lebih dominan dalam proses optimasi. He dan Garcia membahas penanganan ketidakseimbangan kelas melalui pendekatan pada tingkat data maupun algoritma [11]. Beberapa pendekatan yang umum digunakan adalah *oversampling*, *undersampling*, dan pembobotan kelas.

Kondisi tersebut relevan pada klasifikasi Golongan I–V karena jumlah kendaraan pada setiap golongan tidak selalu sama. Oleh sebab itu, evaluasi tidak hanya menggunakan akurasi keseluruhan. Metrik per kelas dan Macro-F1 digunakan untuk melihat apakah model tetap mampu mengenali kelas yang jumlah sampelnya lebih sedikit.

6.4 Kemiripan Antarframe dan Validitas Evaluasi

Citra CCTV bersifat sekuensial sehingga frame yang berdekatan dapat merekam objek, sudut pandang, dan latar belakang yang hampir sama. Jika data yang sangat mirip ditempatkan pada data latih dan data uji, model dapat memperoleh keuntungan dari informasi yang sebenarnya telah muncul pada saat pelatihan. Kondisi ini dapat menghasilkan estimasi performa yang terlalu tinggi.

Kaufman dkk. membahas keadaan tersebut sebagai salah satu bentuk *data leakage*, yaitu masuknya informasi yang seharusnya tidak tersedia pada tahap pelatihan ke dalam proses pembentukan model [6]. Roberts dkk. juga menunjukkan bahwa pembagian acak dapat menghasilkan estimasi performa yang kurang tepat ketika data memiliki struktur temporal, spasial, atau kelompok yang kuat [7].

Pada InaTRC, keterkaitan ini perlu diperiksa pada tingkat frame. Frame yang berurutan, duplikat, atau memiliki kemiripan visual tinggi perlu diperhatikan ketika membentuk data latih, validasi, dan uji. Pemeriksaan tersebut menjadi dasar untuk menentukan apakah pembagian awal dataset dapat digunakan atau perlu disusun kembali pada tingkat kelompok.

6.5 Posisi Penelitian

Penelitian terdahulu telah menunjukkan bahwa golongan kendaraan jalan tol Indonesia dapat dipelajari dari informasi visual pada citra [2], [3]. InaTRC kemudian menyediakan data yang lebih dekat dengan kondisi pemantauan menggunakan CCTV jalan tol [4]. Berdasarkan kondisi tersebut, masih terdapat ruang untuk mengkaji bagaimana pendekatan berbasis fitur *handcrafted* bekerja pada data CCTV dengan variasi ukuran objek, ketidakseimbangan kelas, dan kemiripan antarframe.

Penelitian ini menggunakan HOG sebagai representasi fitur awal dan pengklasifikasi klasik untuk memetakan fitur tersebut ke Golongan I–V. Analisis tidak hanya diarahkan pada nilai performa akhir, tetapi juga pada pengaruh pembentukan ROI, resolusi citra, penanganan ketidakseimbangan kelas, dan pembagian data. Hasilnya diharapkan dapat memberikan baseline yang jelas sekaligus menunjukkan kondisi yang menjadi keterbatasan pendekatan klasik pada InaTRC.

VII. Usulan Metode

7.1 Jenis dan Pendekatan Penelitian

Penelitian ini menggunakan pendekatan kuantitatif eksperimental melalui penerapan teknik pengolahan citra digital dan algoritma *machine learning* klasik pada citra CCTV. Citra dan anotasi InaTRC digunakan untuk memperoleh ROI kendaraan, kemudian ROI diproses menjadi representasi fitur dan diklasifikasikan ke dalam lima golongan. Agar hasil antarpercobaan dapat dibandingkan, pembagian data dan metrik evaluasi dijaga sama ketika satu faktor eksperimen diubah.

Alur penelitian mengikuti tahapan AESFERM (*Acquisition, Enhancement, Segmentation, Feature Extraction, Encoding, Representation, Matching*). Kerangka ini digunakan untuk menata proses pengolahan citra dan klasifikasi secara sistematis, sedangkan konfigurasi pada setiap tahap ditentukan melalui eksperimen.

7.2 Data Penelitian

Penelitian menggunakan InaTRC sebagai dataset utama. Dataset ini terdiri atas 3.250 citra CCTV jalan tol dengan anotasi *bounding box* kendaraan untuk lima golongan serta menyediakan pembagian awal berupa 2.600 citra latih, 325 citra validasi, dan 325 citra uji [4]. Sebelum digunakan, citra dan anotasi diperiksa untuk memastikan file dapat dibaca, koordinat *bounding box* berada dalam batas citra, dan label kelas sesuai dengan lima golongan kendaraan.

Eksplorasi awal dilakukan untuk melihat distribusi jumlah sampel tiap kelas, ukuran

dan rasio aspek ROI, serta kemungkinan adanya citra duplikat atau frame dengan kemiripan tinggi. Hasil pemeriksaan digunakan untuk menilai kelayakan pembagian awal dataset.

Jika ditemukan frame yang sangat berkaitan pada subset berbeda, data akan dikelompokkan berdasarkan informasi temporal, kemiripan citra, atau indikator lain yang tersedia, kemudian dipisahkan pada tingkat kelompok. Data uji akhir tidak digunakan untuk memilih konfigurasi fitur, parameter model, maupun strategi penanganan ketidakseimbangan kelas.

7.3 Tahapan Penelitian

a. Akuisisi Data (Acquisition)

Citra dan anotasi dataset dibaca dan diperiksa kelengkapannya. Statistik dasar seperti jumlah sampel tiap kelas, ukuran ROI, rasio aspek kendaraan, dan distribusi ukuran objek dihitung pada tahap ini. Pemeriksaan terhadap citra duplikat atau frame yang sangat mirip juga dilakukan sebagai dasar penentuan pembagian data.

b. Perbaikan Citra (Enhancement)

Sebagai konfigurasi awal, ROI kendaraan dikonversi ke *grayscale* dan dinormalisasi ukurannya dengan tetap mempertahankan rasio aspek untuk mengurangi distorsi bentuk. Beberapa resolusi masukan dapat dibandingkan untuk melihat pengaruh jumlah detail visual yang tersedia. Normalisasi intensitas dapat digunakan sebagai variasi tambahan apabila diperlukan dalam eksperimen.

c. Segmentasi (Segmentation)

Dalam kerangka AESFERM, tahap segmentasi digunakan untuk mengisolasi ROI kendaraan berdasarkan anotasi *ground-truth bounding box*. Selain ROI sesuai anotasi, digunakan pula variasi ROI dengan konteks terbatas di sekitar objek. Area di sekitar bagian bawah kendaraan menjadi perhatian karena berpotensi memuat informasi mengenai roda dan gandar yang relevan untuk membedakan Golongan II–V.

d. Ekstraksi Fitur (Feature Extraction)

Histogram of Oriented Gradients (HOG) digunakan sebagai representasi fitur awal untuk menangkap bentuk dan struktur tepi kendaraan [8]. Variasi yang diuji terutama berkaitan dengan resolusi citra, skala HOG, dan cakupan ROI. Sebagai pembanding, HOG dapat dikombinasikan atau dibandingkan dengan fitur *handcrafted* lain yang mewakili informasi visual berbeda.

e. Pengodean dan Representasi (Encoding & Representation)

Deskriptor hasil ekstraksi diubah menjadi vektor fitur berdimensi tetap. Jika digunakan lebih dari satu representasi, fitur diuji secara terpisah atau digabungkan menjadi satu vektor. Setiap konfigurasi dibandingkan pada pembagian data yang sama agar pengaruh perubahan representasi dapat diamati secara langsung.

f. Klasifikasi (Matching)

Vektor fitur digunakan sebagai masukan bagi pengklasifikasi *machine learning* klasik. LightGBM digunakan sebagai salah satu model awal [10]. Sebagai pembanding, dapat

digunakan pengklasifikasi klasik seperti Support Vector Machine atau Random Forest pada representasi fitur yang sama.

Ketidakseimbangan jumlah sampel antarkelas ditangani pada tahap pelatihan. Salah satu strategi yang diuji adalah pembobotan kelas berdasarkan frekuensi sampel [11],

$$w_c = \frac{N}{KN_c}, \quad (3)$$

dengan N sebagai jumlah seluruh sampel pelatihan, K sebagai jumlah kelas, dan N_c sebagai jumlah sampel pada kelas c . Strategi ini dibandingkan dengan pelatihan tanpa pembobotan. Apabila teknik sampling digunakan, penerapannya dibatasi pada data pelatihan.

7.4 Rancangan Eksperimen


Eksperimen dimulai dari satu konfigurasi awal yang digunakan sebagai acuan. Faktor yang berkaitan dengan ROI, representasi fitur, ketidakseimbangan kelas, dan pengklasifikasi kemudian diuji secara bertahap. Pada setiap kelompok eksperimen, faktor yang sedang diamati diubah sedangkan kondisi utama lain dipertahankan sejauh memungkinkan. Dengan rancangan ini, perubahan performa dapat dikaitkan dengan faktor yang sedang diuji.

Kelompok faktor yang direncanakan ditunjukkan pada Tabel 1.

Tabel 1: Kelompok faktor yang digunakan dalam rancangan eksperimen.

Faktor	Variasi yang dapat diuji	Tujuan analisis
ROI dan resolusi	ROI sesuai anotasi, ROI dengan konteks terbatas, dan beberapa resolusi masukan	Menilai pengaruh cakupan objek dan detail visual kendaraan
Representasi fitur	HOG, variasi skala HOG, dan kombinasi dengan fitur <i>handcrafted</i> lain	Menilai kemampuan fitur dalam membedakan karakteristik antargolongan
Ketidakseimbangan kelas	Tanpa penanganan khusus, pembobotan kelas, dan sampling pada data latih	Menilai perubahan performa pada kelas mayoritas dan minoritas
Pengklasifikasi	LightGBM serta pengklasifikasi klasik pembanding	Menilai pengaruh pilihan model pada representasi fitur yang sama

Konfigurasi dikembangkan dan dibandingkan menggunakan data latih dan data validasi. Setelah konfigurasi utama ditentukan, model dievaluasi pada data uji yang tidak digunakan selama proses pemilihan. Jika *cross-validation* digunakan sebagai analisis tambahan, pemisahan fold tetap mengikuti kelompok data agar frame yang berkaitan tidak tersebar antara data pelatihan dan validasi.



Gambar 2: Rancangan eksperimen dan penggunaan data pada setiap tahap.

7.5 Evaluasi Model

Metrik utama yang digunakan adalah Macro-F1 [12]. Untuk setiap kelas c , nilai *precision* dan *recall* didefinisikan sebagai

$$P_c = \frac{TP_c}{TP_c + FP_c}, \quad R_c = \frac{TP_c}{TP_c + FN_c}, \quad (4)$$

dengan TP_c , FP_c , dan FN_c masing-masing menunjukkan jumlah *true positive*, *false positive*, dan *false negative* untuk kelas c .

Nilai F1 untuk setiap kelas dihitung sebagai

$$F1_c = 2 \frac{P_c R_c}{P_c + R_c}. \quad (5)$$

Macro-F1 kemudian dihitung sebagai rata-rata F1 seluruh kelas,

$$\text{MacroF1} = \frac{1}{K} \sum_{c=1}^K F1_c, \quad (6)$$

dengan $K = 5$. Macro-F1 dipilih karena memberikan bobot yang sama pada setiap golongan sehingga hasil tidak didominasi oleh kelas dengan jumlah sampel terbesar.

Metrik pendukung yang dilaporkan meliputi *balanced accuracy*, akurasi, *precision*, *recall*, dan F1 tiap kelas, serta *confusion matrix*. Analisis per kelas digunakan untuk melihat pasangan golongan yang paling sering tertukar. Performa juga dianalisis terhadap ukuran ROI pada citra asli, variasi resolusi masukan, dan penggunaan konteks di sekitar kendaraan.

Jika jumlah kelompok data memadai, kestabilan hasil akan diperiksa melalui evaluasi berulang atau interval kepercayaan yang tetap mempertahankan struktur kelompok. Analisis ini digunakan untuk melihat seberapa konsisten performa model terhadap variasi sampel pengujian.

Daftar Pustaka

- [1] Kementerian Pekerjaan Umum Republik Indonesia, *Keputusan Menteri Pekerjaan Umum Nomor 1442/KPTS/M/2025 tentang Penetapan Golongan Jenis Kendaraan Bermotor dan Penyesuaian Tarif Tol pada Ruas Jalan Tol Solo–Mantingan–Ngawi*, Jaringan Dokumentasi dan Informasi Hukum Kementerian Pekerjaan Umum, Lampiran I memuat klasifikasi Golongan I–V, 2025. [Online]. Available: <https://jdih.pu.go.id/internal/assets/assets/produk/KepmenPUPR/2025/12/2025kmpu1442.pdf>.
- [2] A. T. Sasongko and M. I. Fanany, “Indonesia Toll Road Vehicle Classification Using Transfer Learning with Pre-Trained ResNet Models,” in *2019 2nd International Seminar on Research of Information Technology and Intelligent Systems (ISRITI)*, IEEE, 2019, pp. 373–378. doi: 10.1109/ISRITI48646.2019.9034590.
- [3] A. T. Sasongko, G. Jati, M. I. Fanany, and W. Jatmiko, “Dataset of Vehicle Images for Indonesia Toll Road Tariff Classification,” *Data in Brief*, vol. 32, p. 106061, 2020. doi: 10.1016/j.dib.2020.106061.
- [4] U. Chasanah et al., *InaTRC: Indonesia Toll Road Vehicle Classification Dataset*, version 1, 2025. doi: 10.17632/kddgphck3b.1. [Online]. Available: <https://data.mendeley.com/datasets/kddgphck3b/1>.
- [5] U. Chasanah, G. M. Putra, S. Bismantoko, S. Hidayat, T. Widodo, and M. Rosyidi, “saLFIA: Semi-automatic Live Feeds Image Annotation Tool for Vehicle Classification Dataset,” *Journal of ICT Research and Applications*, vol. 18, no. 2, pp. 143–154, 2024. doi: 10.5614/itbj.ict.res.appl.2023.18.2.5.
- [6] S. Kaufman, S. Rosset, and C. Perlich, “Leakage in Data Mining: Formulation, Detection, and Avoidance,” in *Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, ACM, 2011, pp. 556–563. doi: 10.1145/2020408.2020496.
- [7] D. R. Roberts et al., “Cross-validation Strategies for Data with Temporal, Spatial, Hierarchical, or Phylogenetic Structure,” *Ecography*, vol. 40, no. 8, pp. 913–929, 2017. doi: 10.1111/ecog.02881.
- [8] N. Dalal and B. Triggs, “Histograms of Oriented Gradients for Human Detection,” in *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR’05)*, vol. 1, IEEE, 2005, pp. 886–893. doi: 10.1109/CVPR.2005.177.
- [9] R. S. El-Sayed and M. N. El-Sayed, “Classification of Vehicles’ Types Using Histogram Oriented Gradients: Comparative Study and Modification,” *IAES International Journal of Artificial Intelligence*, vol. 9, no. 4, pp. 700–712, 2020. doi: 10.11591/ijai.v9.i4.pp700-712.
- [10] G. Ke et al., “LightGBM: A Highly Efficient Gradient Boosting Decision Tree,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.

- [11] H. He and E. A. Garcia, “Learning from Imbalanced Data,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009. DOI: 10.1109/TKDE.2008.239.
- [12] M. Sokolova and G. Lapalme, “A Systematic Analysis of Performance Measures for Classification Tasks,” *Information Processing & Management*, vol. 45, no. 4, pp. 427–437, 2009. DOI: 10.1016/j.ipm.2009.03.002.